


UNIVERSIDAD
EAFIT



Análisis automatizado de imágenes para la detección de antracnosis en frutos de aguacate (*Persea americana* Mill)

Yeison Arango Ospina - Jayder Andres Juagibioy Satiaca - Sara Gallego Thorne

Bigdata & Bioinformática
Ingeniería Agronómica

Introducción

El aguacate es clave en la economía de Antioquia, pero enfrenta pérdidas por antracnosis, una enfermedad causada por un hongo. Su detección es difícil por infecciones latentes. Se propone usar Machine Learning con imágenes para identificarla a tiempo y mejorar el manejo del cultivo de forma sostenible.



Imagen 1. Aguacates.

Objetivo general:

Desarrollar un modelo de aprendizaje profundo para clasificar frutos de aguacate (*Persea americana* Mill.) como sanos o afectados por antracnosis, utilizando imágenes etiquetadas y validando su desempeño con un modelo basado en Random Forest.

Objetivos específicos:

1. Entrenar un modelo de Machine Learning utilizando un conjunto de datos de imágenes de aguacate, con el fin de identificar la presencia de antracnosis.
2. Validar la veracidad de las predicciones del modelo entrenado mediante la comparación de resultados con un clasificador Random Forest, evaluando métricas como precisión, sensibilidad y especificidad.



Descripción del DataSet

Se utilizó el dataset público “Clasificación de enfermedades con Deep Learning” de Kaggle, diseñado para entrenar modelos de clasificación de enfermedades en frutas.


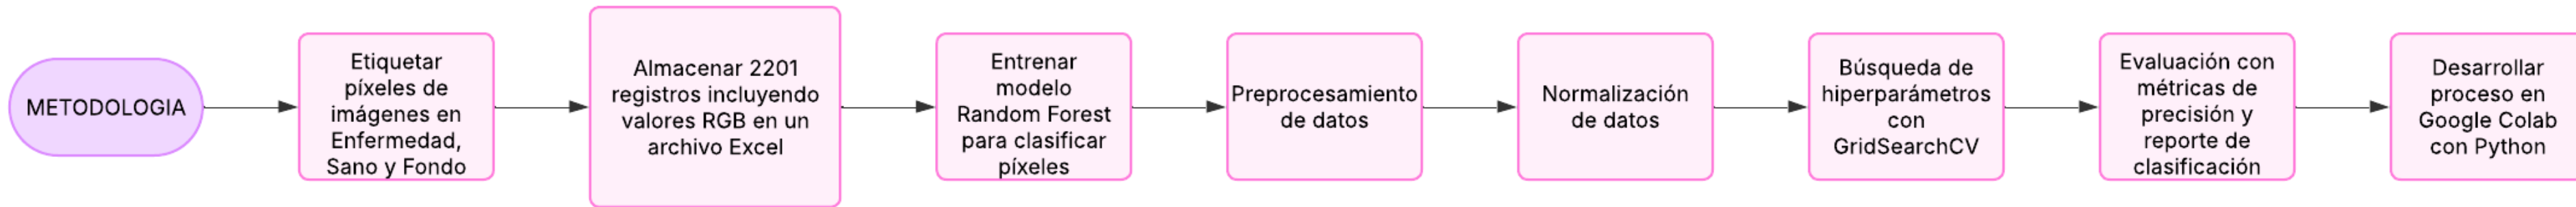
- El conjunto original contiene 669 imágenes en tres clases:
 - Frutos sanos (S)
 - Frutos con antracnosis (A)
 - Frutos con roña (R)
- Para este estudio, se seleccionaron solo dos clases:
 - 288 imágenes de frutos sanos
 - 178 imágenes de frutos con antracnosis

Se excluyó la clase “roña” .



Gráfica 2. Ejemplo de imágenes de aguacates.

Metodología Procesamiento.




Gráfica 3. Ejemplo de imágenes de aguacates.

	A	B	C	D
1	R	G	B	X
2	111	109	110	1
3	100	99	94	1
4	89	85	76	1
5	121	122	117	1
6	137	125	101	1
7	130	132	129	1
8	102	93	86	1
9	108	104	95	1
10	106	98	87	1
11	105	97	86	1
12	144	133	113	1
13	76	76	74	1
14	68	68	70	1
15	118	115	108	1
16	128	125	110	1
17	137	103	65	1

Gráfica 4. Ejemplo de toma de datos.

Resultados

El modelo mostró un desempeño sobresaliente en la clasificación de frutos de aguacate. Identificó correctamente casi la totalidad de frutos enfermos y sanos, con muy pocos errores entre ambas clases. La clase "fondo" fue clasificada con total precisión. Estos resultados reflejan una alta capacidad del modelo para diferenciar entre frutos afectados por antracnosis, sanos y el fondo, incluso en presencia de ruido visual.



Gráfica 5. Matriz de confusión del modelo Random Forest entrenado para la clasificación.

Resultados

El modelo alcanzó un 99% de precisión (accuracy) en la clasificación de frutos de aguacate. Las métricas de precisión, recall y F1-score fueron altas en todas las clases, destacando la capacidad del modelo para identificar correctamente tanto frutos sanos como enfermos. Estos resultados evidencian una alta confiabilidad y robustez en la segmentación y diagnóstico automatizado de antracnosis.

	Precision	Recall	F1-score	Support
1	98	99	98	1000
2	99	98	98	1000
3	1	1	1	200
accuracy	-	-	99	2200
Macro avg	99	99	99	2200
Weighted avg	99	99	99	2200

Tabla 1. Reporte de clasificación del modelo Random Forest entrenado para clasificación.


Análisis

El modelo logró una precisión del 99% en la detección de antracnosis, incluso identificando áreas enfermas en imágenes catalogadas como sanas, lo que refleja alta sensibilidad. A pesar del tamaño moderado del dataset (669 imágenes), el éxito se atribuye al etiquetado detallado por píxel, que permitió captar características sutiles a partir de datos RGB.


Original: A.169.jpg



Segmentación



Estado: Enfermo



Original: S.181.jpg

Segmentación

Estado: Sano

Gráfica 6. Ejemplo de Resultado de la Segmentación y Clasificación de imágenes de aguacates.

Conclusiones

- El modelo de aprendizaje automático logró una alta precisión (98%) al clasificar aguacates sanos y enfermos, demostrando ser eficaz en la detección de antracnosis a pesar de utilizar un número limitado de imágenes de entrenamiento de alta calidad.
- Esta investigación sugiere que el aprendizaje automático puede ser una herramienta valiosa para mejorar la sanidad vegetal y apoyar las decisiones de manejo fitosanitario en el aguacate, incluso con conjuntos de datos sencillos pero bien estructurados.


Resumen:

Este estudio usó aprendizaje automático con imágenes para detectar antracnosis en aguacates, logrando 99% de precisión con Random Forest. Demuestra su utilidad para diagnóstico temprano en agricultura de precisión.


Original: A.169.jpg



Segmentación



Estado: Enfermo



Original: S.181.jpg

Segmentación

Estado: Sano

Gráfica 1. Ejemplo de Resultado de la Segmentación y Clasificación de imágenes de aguacates.

Bibliografía

- [1] Romero Sánchez, M. A. (2012). Comportamiento fisiológico del aguacate (*Persea americana* mill.) Variedad Lorena en la zona de Mariquita, Tolima. Universidad Nacional de Colombia Facultad de Agronomía, Escuela de Posgrados Bogotá, Colombia.
- [2] Salazar-García, S. (2002). Nutrición del Aguacate, Principios y Aplicaciones. Queretaro, México: INPOFOS. Instituto de la potasa y el fosforo A.C.
- [3] Rodríguez, A. T., Dávila, J. F. R., Siclán, M. L. S., Vildózola, Á. C., Zamora, F. I. M., & Díaz, A. V. L. (2020). Distribución espacial de antracnosis (*Colletotrichum gloeosporioides* Penz) en aguacate en el Estado de México, México. Revista Argentina de Microbiología, 52(1), 72-81. <https://doi.org/10.1016/j.ram.2019.07.004>
- [4] Antracnosis en el Cultivo de Aguacate | Intagri S.C. (s. f.). <https://www.intagri.com/articulos/fitosanidad/antracnosis-en-el-cultivo-de-aguacate>
- [5] Morales-García, J. L., López-Cornejo, C. I., Pedraza-Santos, M. E., Chávez-Bárcenas, A. T., Esquivel-Miguel, E., García-Morales, S., & Pineda-Guillermo, S. (2023). Morpho-molecular identification of the causal agent of avocado scab in Michoacán. Revista Mexicana de Fitopatología(En Línea)/Revista Mexicana de Fitopatología, 41(2). <https://doi.org/10.18781/r.mex.fit.2302-4>
- [6] Warman, C., & Fowler, J. E. (2021). Deep learning-based high-throughput phenotyping can drive future discoveries in plant reproductive biology. Plant Reproduction, 34(2), 81-89. <https://doi.org/10.1007/s00497-021-00407-2>

GRACIAS




Agregar un título

Agregar un subtítulo

Agregar algo de texto

Agregar un título

Agregar algo de texto



Titulo aqui

Agregar un subtítulo

Agregar algo de texto

Titulo aqui

Agregar un subtítulo

Agregar algo de texto

Titulo aqui

Agregar un subtítulo

Agregar algo de texto

Agregar un subtítulo

**Agregar un
título**

Agregar algo de texto